



ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Dipartimento di Informatica Scienza e Ingegneria

Corso di Laurea in Informatica

Traduzione da linguaggio naturale a query per Blazegraph

Relatore:
Chiar.mo Prof.
Fabio Vitali

Presentata da:
Alberto Zuccari

I Sessione 2026
Anno Accademico 2025/2026

(DA FARE ALLA FINE)

5 parole chiave per caratterizzare il contenuto della dissertazione:

parola 5

parola 4

parola 3

parola 2

Parola 1

*Non tocca a noi dominare tutte le maree del mondo
il nostro compito è di fare il possibile
per la salvezza degli anni nei quali viviamo*

- J.R.R. Tolkien

Abstract

Abstract qui (da completare alla fine).

Indice

1	Introduzione	1
2	Contesto scientifico e tecnologico	3
3	Il prototipo	5
3.1	Introduzione al capitolo	5
3.2	Il dominio e gli utenti target	5
3.2.1	Il contesto operativo: DH.ARC e il Datavault	6
3.2.2	Profilo dell'utente finale: i ricercatori del centro	7
3.3	Architettura dell'informazione e trovabilità	8
3.3.1	Il paradigma classico: navigazione e filtri	10
3.3.2	Il nuovo paradigma: ricerca semantica con LLM	10
3.4	Architettura Funzionale (Ad alto livello)	10
3.4.1	Il flusso dell'interazione	10
3.4.2	Diagramma funzionale del sistema	10
3.4.3	I componenti del sistema e le loro responsabilit�	10
3.5	Casi d'uso principali	10
3.5.1	Caso d'uso 1: ricerca per caratteristiche di acquisizione	10
3.5.2	Caso d'uso 2: ricerca per progetto e tipologia di risorsa	10
3.5.3	Caso d'uso 3: ricerca multi-criterio con filtro temporale	10
3.6	Conclusioni del capitolo	10
4	Architettura e dettagli implementativi	11
5	Valutazione	13
6	Conclusioni e sviluppi futuri	15
	Riferimenti bibliografici	17

Elenco delle tabelle

Elenco delle figure

Capitolo 1

Introduzione

Scrivi qui il contenuto dell'introduzione.

Capitolo 2

Contesto scientifico e tecnologico

Scrivi qui il contenuto del capitolo 1 sul contesto scientifico.

Capitolo 3

Il prototipo

3.1 Introduzione al capitolo

Presentiamo l'idea di un LLM Query Builder come strumento che possa assistere i ricercatori del FICLIT (Dipartimento di Filologia Classica e Italianistica) nella ricerca all'interno del Datavault, un repository curato dal DH.ARC (Digital Humanities Advanced Research Centre) dell'Università di Bologna. Lo scopo di questo capitolo è quello di presentare il prototipo di tale strumento e di discutere le sue potenzialità e i suoi limiti.

Questa implementazione assiste un utente ipotetico, un ricercatore del FICLIT, come un umanista qualsiasi, che non si sia mai interfacciato con l'applicativo, il team di ricerca o, banalmente, un triplestore RDF e l'interrogazione via SPARQL. Chapter 2 Questo tipo di figure professionali non sono sempre avvezze all'utilizzo di strumenti come i database relazionali o graph, anzi. Spesso non hanno nemmeno idea di cosa siano o come funzionino. Per tale motivo, è necessario fornire loro uno strumento che sia in grado di tradurre le loro esigenze in un linguaggio che possa essere compreso dal database.

Andremo ora a descrivere il dominio degli utenti con i relativi bisogni informativi [Section 3.2], passando poi ad analizzare come l'Intelligenza Artificiale (IA) modifichi il paradigma di esplorazione del dato [Section 3.3], per poi presentare l'architettura del sistema proposta in questo elaborato [Section 3.4], andando poi ad illustrare tre scenari d'uso concreti [Section 3.5], e concludendo il capitolo con un riassunto dei punti chiave presentati [Section 3.6].

3.2 Il dominio e gli utenti target

In questa sezione viene definito il contesto d'uso all'interno delle Digital Humanities (DH) e del Patrimonio Culturale (PC), evidenziando il divario tra i complessi bisogni esplorativi dei ricercatori e la rigidità strutturale dei sistemi di Information Retrieval (IR) basati su linguaggi formali.

L'accesso a basi di dati eterogenee tramite strumenti come SPARQL rappresenta una barriera significativa per chi non possiede competenze tecniche avanzate. Come evidenziato in letteratura, lavorare con questi strumenti impone vincoli rigorosi[VFQP25] e richiede una profonda familiarità con le convenzioni dei metadati[Vaš24]. Tali approcci si basano su query create manualmente che risultano fragili e difficili da adattare a esigenze mutevoli[Mar25]. Questo pone il ricercatore di fronte all'ostacolo cognitivo della “scatola vuota”, un limite particolarmente penalizzante per chi ha obiettivi di ricerca non ancora perfettamente focalizzati.

Alla base dei tradizionali sistemi di IR vi è l'assunto che l'utente inizi l'interazione possedendo un bisogno informativo perfettamente strutturato. Nel dominio umanistico, al contrario, l'utente procede per esplorazione. Questo comportamento è ben descritto dal modello della “raccolta delle bacche” (berrypicking) teorizzato da Marcia Bates[Bat89]: una strategia di ricerca non lineare in cui gli studiosi si muovono iterativamente, aggiustando la rotta man mano che acquisiscono nuove informazioni. In un simile scenario di *ricerca esplorativa*, assume un valore inestimabile il fenomeno della *serendipity*, ovvero la scoperta inattesa di pattern rilevanti durante la navigazione dei dati.

Considerando il netto contrasto tra la rigidità sintattica di SPARQL e la natura fluida ed evolutiva della ricerca umanistica, emerge la necessità di un nuovo paradigma di interazione. L'introduzione di un'architettura basata su un LLM Query Builder si pone come la soluzione tecnologica ideale per colmare questo divario. Sfruttando il linguaggio naturale, il sistema abbate le barriere d'ingresso e agisce come un intermediario semantico in grado di assecondare l'assenza iniziale di query perfette, accompagnando l'utente in un'esplorazione iterativa del patrimonio culturale.

3.2.1 Il contesto operativo: DH.ARC e il Datavault

Il Digital Humanities Advanced Research Centre (DH.ARC) è un polo di ricerca dell'Università di Bologna afferente al Dipartimento di Filologia Classica e Italianistica (FICLIT), nato con l'obiettivo di “connettere studenti, ricercatori, personale IT e professori del FICLIT e del Dipartimento di Informatica - Scienza e Ingegneria (DISI)”[ALM26]. Il centro ha lo scopo di fungere da hub per gli studiosi e le istituzioni, supportandoli “nella progettazione, sviluppo e manutenzione di progetti di ricerca DH” e promuovendo iniziative innovative nel campo umanistico. Le attività di ricerca vertono prevalentemente sulla digitalizzazione e creazione di metadati per il patrimonio culturale, che includono in gran parte “documenti archivistici e libri antichi”, “testi letterari” e “knowledge graphs che descrivono oggetti del patrimonio culturale” come fotografie e opere d'arte. In questo ecosistema si inserisce il Datavault, un database RDF (basato su Blazegraph) che funge da enorme bacino di immagazzinamento delle informazioni. Il Datavault “contiene, ad ora, 19 milioni di triple tutte molto simili”, dotate di uno specifico “schema RDF reale”. Proprio a causa di questa vastità e similarità strutturale, “andare a cercare il file specifico non è cosa semplice ed immediata”: attualmente manca infatti un modo per “interrogare i dati per contenuto o concetto, nonostante Blazegraph renda l'informazione potenzialmente ricercabile in modo flessibile” “.

3.2.2 Profilo dell'utente finale: i ricercatori del centro

Profilo disciplinare e competenze tecniche dei ricercatori

L'utenza di riferimento del centro DH.arc è composta da docenti, ricercatori, assegnisti e studenti di discipline prettamente umanistiche, quali filologia, storia, storia dell'arte e archeologia.[PT22] Questi studiosi sono molto competenti nel dominio delle fonti culturali e nell'analisi dei testi critici, ma tipicamente sono privi di un background informatico formale. La loro alfabetizzazione digitale nel campo dell'Information Retrieval si limita solitamente all'impiego di strumenti "pronti all'uso": cataloghi OPAC, database relazionali con maschere pre-configurate o motori di ricerca generici.

Caratterizzazione dei bisogni informativi

In questo ecosistema, gli utenti non ricercano identificativi esatti o risposte chiuse; piuttosto, adottano comportamenti di ricerca esplorativa, procedendo per esplorazione libera al fine di collegare concetti e scoprire associazioni non immediate tra i documenti. Interrogando il Datavault, gli umanisti del centro necessitano di porre interrogazioni cross-dominio articolate, formulando mentalmente domande come: "Quali immagini di codici medievali del XIV secolo sono state digitalizzate con risoluzione superiore a 300 dpi nel corso del progetto X? " oppure "Mostrami tutti i manoscritti attribuiti a un determinato autore e digitalizzati nell'ultimo anno".

La triplice barriera di SPARQL come ostacolo insormontabile

Costringere questa tipologia di utenti a esprimere bisogni complessi tramite endpoint SPARQL genera un grande ostacolo, sintetizzabile attraverso tre livelli di difficoltà:

1. Barriera cognitiva: L'interazione esige la scrittura in un linguaggio dichiarativo formale e l'obbligo di conoscere complessi prefissi ontologici (es. `dc:`, `exif:`, `ebucore:`) per poter anche solo abbozzare una query di base.
2. Barriera strutturale: L'assenza di uno schema grafico fisso o di una mappa visiva delle relazioni all'interno del grafo RDF fa sì che l'utente non sappia quali proprietà esistano realmente nel database né come i dati siano formalizzati nell'ontologia.
3. Barriera pratica: La forte rigidità sintattica determina che un singolo errore di battitura o la mancanza di una corrispondenza esatta produca un set di risultati vuoto. L'assenza di messaggi di errore parlanti impedisce qualsiasi tentativo di debugging autonomo.

Studi sull'usabilità delle interfacce per Knowledge Graph confermano che linguaggi come SPARQL impongono vincoli rigidi e richiedono un'esplicita conoscenza degli schemi, competenze estranee ai professionisti del patrimonio culturale.[VFQP25] Emerge dunque la necessità ineludibile di un LLM Query Builder che, traducendo il linguaggio naturale, svincoli il ricercatore dalle rigidità sintattiche e renda possibile una reale esplorazione dei dati.

3.3 Architettura dell'informazione e trovabilità

La progettazione di un sistema di accesso per un database RDF contenente milioni di triple non può limitarsi alla pura efficienza computazionale del recupero dati, ma deve rispondere ai principi fondamentali dell'architettura dell'informazione per garantire la reale “trovabilità” delle risorse. In un contesto umanistico, costringere l'utente a interfacciarsi con la complessità dello schema sottostante attraverso interfacce a filtri rigidi o linguaggi formali genera un grande ostacolo cognitivo. L'adozione di un LLM Query Builder, in quest'ottica, non rappresenta un vezzo tecnologico, ma una precisa scelta di design intenta a ristabilire un'interazione naturale tra l'utente e i dati, come dimostrato dai seguenti principi fondativi della disciplina.

L'illusione della ricerca algoritmica.

I tradizionali sistemi di reperimento dei dati basati su query formali (come SQL o SPARQL) assumono erroneamente che l'utente sappia sempre cosa cercare e come tradurre il proprio bisogno in un costrutto logico. Peter Morville e Louis Rosenfeld smontano questo assunto, definendolo un grave errore concettuale nel campo dell'architettura dell'informazione:

“Consideriamo questo modello pericoloso perché basato su un equivoco: che trovare informazioni sia un problema diretto, che può essere risolto da un semplice approccio algoritmico. Dopo tutto, abbiamo risolto la sfida del recupero dati — che, ovviamente sono fatti e cifre — con tecnologie database come SQL. Così procede la teoria, si trattano idee e concetti incorporati nei documenti testuali semistrutturati nello stesso modo. ”

[MR08]

I sistemi algoritmici tradizionali falliscono nel dominio umanistico perché sono progettati per recuperare dati esatti, mentre gli studiosi ricercano concetti, idee e relazioni. Tali concetti sono per loro natura ambigui e sfumati. L'LLM Query Builder colma esattamente questo divario: funge da traduttore semantico che accetta l'ambiguità e la ricchezza del linguaggio naturale del ricercatore e lo converte in modo trasparente nell'approccio algoritmico richiesto dalla macchina per interrogare il Datavault.

Il bilanciamento iterativo tra Recall e Precision.

Un altro problema critico delle interfacce tradizionali a filtri rigidi è l'impossibilità di calibrare dinamicamente e in modo intuitivo il raggio della ricerca. Morville e Rosenfeld spiegano che ogni ricerca è un compromesso matematico tra due metriche inversamente proporzionali:

$$\text{recall} = \frac{|\text{doc rilevanti recuperati}|}{|\text{doc nella raccolta}|} \quad (3.1)$$

$$\text{precision} = \frac{|\text{doc rilevanti recuperati}|}{|\text{doc rilevanti della raccolta}|} \quad (3.2)$$

“[...] Non sarebbe bello poter ottenere contemporaneamente elevati valori di recall e precision? Purtroppo non si può avere botte piena e moglie ubriaca: recall e precision sono inversamente correlati” [MR08].

In un’interfaccia a maschera con decine di campi e filtri ontologici, l’utente è costretto a dichiarare a priori il livello di precisione desiderato. Se sbaglia un filtro, ottiene zero risultati (eccesso di Precision); se ne omette uno, viene sommerso da migliaia di risultati irrilevanti (eccesso di Recall). In una conversazione in linguaggio naturale con un LLM, invece, l’aggiustamento del raggio di ricerca avviene in modo iterativo e fluido. L’utente può iniziare con una richiesta esplorativa e ampia (es. “Mostrami tutti i manoscritti del XIV secolo”, privilegiando il Recall) e, osservando i primi risultati, raffinare il tiro conversando (“Filtra solo quelli con miniature e digitalizzati ad alta risoluzione”, aumentando la Precision). L’LLM permette di variare queste metriche dinamicamente senza costringere l’utente a decostruire e riscrivere manualmente una complessa sintassi di query.

La legge del minimo sforzo, l’overload e la Legge di Hick.

Dal punto di vista del carico cognitivo, esporre all’utente l’immensa topologia di un Knowledge Graph da 19 milioni di triple attraverso decine di menu a tendina o l’obbligo di conoscere specifiche ontologie porta inevitabilmente all’abbandono del sistema. Luca Rosati analizza questo fenomeno attraverso due principi cognitivi fondamentali. Il primo è la legge del minimo sforzo:

“La legge del minimo sforzo (least effort) regola quindi il nostro sistema di information seeking, al punto che spesso accettiamo anche contenuti di bassa qualità o affidabilità (se più facili da ottenere e usare) pur di non ricorrere a strategie di ricerca attive, le quali comportano necessariamente sforzi, tempi e competenze maggiori” [Ros07].

Se l’interfaccia richiede la fatica di apprendere prefissi RDF o di comprendere uno schema dati complesso, l’umanista rinuncerà alla ricerca. Si aggiunge poi l’ansia generata dal paradosso della scelta, matematicamente descritto dalla Legge di Hick, la quale stabilisce che il tempo per prendere una decisione (e il relativo stress) aumenta logicamente all’aumentare delle opzioni presentate.

$$\text{tempo} = a + b \log_2(n + 1)$$

Rosati sottolinea che se le opzioni “sono presentate in modo confuso” o rappresentano “una lista di opzioni disordinata (priva cioè di un qualche criterio logico riconoscibile da parte dell’utente)”, il carico cognitivo diventa lineare e insostenibile, causando la paralisi decisionale. Presentare un form di interrogazione SPARQL nudo, o una maschera di ricerca avanzata con decine di menù a tendina che mappano un’intera ontologia, equivale esattamente a questo: esporre l’utente a un “paradosso della scelta” paralizzante.

L’interfaccia conversazionale basata su LLM nasconde questa complessità strutturale nel backend. L’utente si trova di fronte a un singolo “spazio” (un box di chat), azzerando l’effetto della Legge di Hick e assecondando la Legge del minimo sforzo.

Non dovendo più scegliere tra decine di opzioni incomprensibili, il ricercatore delega il carico cognitivo della traduzione ontologica all'LLM, potendo così dedicare le proprie energie intellettuali esclusivamente all'analisi e alla scoperta delle risorse del patrimonio culturale.

3.3.1 Il paradigma classico: navigazione e filtri

L'architettura dell'informazione si definisce come il design strutturale di ambienti informativi finalizzato a plasmare l'usabilità e la trovabilità.[MR08] Poggia su quattro sistemi interconnessi:

- i) sistemi di organizzazione, che categorizzano le informazioni;
- ii) sistemi di etichettatura, che ne determinano la rappresentazione linguistica;
- iii) sistemi di navigazione, che consentono l'orientamento nello spazio;
- iv) sistemi di ricerca, che permettono interrogazioni dirette

Applicato al Datavault, l'interrogazione tradizionale mediante filtri rigidi o SPARQL presenta limiti strutturali. Fallisce per tre ragioni:

1. Pretende conoscenza a priori di stringhe esatte, incompatibile con la ricerca umanistica;[Vaš24]
2. Non gestisce sinonimia, sfumature e vaghezza del linguaggio naturale;
3. Obbliga la formulazione di query multi-criterio in sintassi rigide.

Queste rigidità abbattano la “trovabilità”: l'informazione esiste fisicamente ma rimane irraggiungibile per l'utente.

3.3.2 Il nuovo paradigma: ricerca semantica con LLM

3.4 Architettura Funzionale (Ad alto livello)

3.4.1 Il flusso dell'interazione

3.4.2 Diagramma funzionale del sistema

3.4.3 I componenti del sistema e le loro responsabilità

3.5 Casi d'uso principali

3.5.1 Caso d'uso 1: ricerca per caratteristiche di acquisizione

3.5.2 Caso d'uso 2: ricerca per progetto e tipologia di risorsa

3.5.3 Caso d'uso 3: ricerca multi-criterio con filtro temporale

3.6 Conclusioni del capitolo

Capitolo 4

Architettura e dettagli implementativi

Scrivi qui il contenuto del capitolo 3 sull'architettura e l'implementazione.

Capitolo 5

Valutazione

Scrivi qui il contenuto del capitolo 4 sulla valutazione.

Capitolo 6

Conclusioni e sviluppi futuri

Scrivi qui il contenuto del capitolo 5 sulle conclusioni e gli sviluppi futuri.

Riferimenti bibliografici

- [ALM26] ALMA MATER STUDIORUM - Università di Bologna. /*DH.ARC - Digital Humanities Advanced Research Centre*. <https://centri.unibo.it/dharc/en>, 2026.
- [Bat89] Marcia J. Bates. The design of browsing and berrypicking techniques for the online search interface. *Online Review*, 13(5):407–424, 1989.
- [Mar25] Mohammed Maree. Quantifying relational exploration in cultural heritage knowledge graphs with llms: A neuro-symbolic approach for enhanced knowledge discovery. *Data*, 10(4):52, 2025.
- [MR08] Peter Morville and Louis Rosenfeld. *Information Architecture for the World Wide Web*. O'Reilly Media, Sebastopol, CA, 3 edition, 2008.
- [PT22] Silvio Peroni and Francesca Tomasi. Approaching digital humanities at university: a cultural challenge. *Journal of Art Historiography*, 27, December 2022.
- [Ros07] Luca Rosati. *Architettura dell'informazione: Guida alla trovabilità, dagli oggetti quotidiani al Web*. Apogeo, 2007.
- [Tol70] J. R. R. Tolkien. *Il Signore degli Anelli*. Bompiani, 1970.
- [Vaš24] Linas Vaštakas. Cultural heritage search with large language models: Enhancing the discoverability of cultural heritage artifacts through large language model-based search systems. Master's thesis, Linnaeus University, Sweden, 2024.
- [VFQP25] Iva Vasic, Hans-Georg Fill, Ramona Quattrini, and Roberto Pierdicca. Knowledge graphs vs. large language models: Competitors or partners in supporting virtual museums. *ACM Journal on Computing and Cultural Heritage*, 18(4), dec 2025.

Ringraziamenti

Grazie a tutt*.